

تحلیل احساسات متون با استفاده از روش TF-IDF

گزارش پروژه درس پردازش زبان طبیعی — تیر ۱۴۰۵

پیاده‌سازی کامل از پایه با پایتون خالص، بدون استفاده از کتابخانه‌های آماده

۱. مقدمه

هدف این پروژه، تحلیل احساسات (Sentiment Analysis) جمله‌های نظرات کاربران و طبقه‌بندی آن‌ها به دو کلاس «مثبت» و «منفی» است. برای این کار، متن‌ها پس از پیش‌پردازش، با روش TF-IDF به بردار ویژگی تبدیل می‌شوند و سپس یک مدل Multinomial Naive Bayes روی آن‌ها آموزش می‌بیند.

نکته متمایز این پروژه آن است که تمام مراحل — از پاک‌سازی متن و توکن‌سازی تا محاسبه TF-IDF و خود الگوریتم بیز ساده — به صورت دستی و از پایه با پایتون خالص پیاده‌سازی شده‌اند و از هیچ کتابخانه آماده‌ای (مانند scikit-learn، NLTK یا حتی NumPy) استفاده نشده است. این انتخاب باعث می‌شود سازوکار درونی هر مرحله کاملاً شفاف و قابل توضیح باشد. ماتریس‌ها به صورت لیست‌های تودرتوی پایتون نگهداری می‌شوند و تنها ماژول‌های استاندارد math و re به کار رفته‌اند.

خروجی برنامه (main.py) یک برنامه تعاملی خط فرمان است که پس از آموزش، هر جمله‌ای را که کاربر وارد کند طبقه‌بندی می‌کند و با دستورهای داخلی، ارزیابی کامل (eval)، کلمات مؤثر هر کلاس (words:) و نمونه‌های اشتباه طبقه‌بندی شده (mistakes:) را نمایش می‌دهد.

۲. معرفی دیتاست

از مجموعه داده **Sentiment Labelled Sentences** (مخزن یادگیری ماشین UCI) استفاده شده است. این مجموعه شامل سه فایل از سه دامنه متفاوت است و در هر فایل، هر سطر یک جمله و برچسب آن به صورت sentence<TAB>label آمده است؛ برچسب ۱ به معنی مثبت و برچسب ۰ به معنی منفی است.

فایل	دامنه	تعداد جمله	مثبت	منفی	نقش در پروژه
imdb_labelled.txt	نقد فیلم	۱۰۰۰	۵۰۰	۵۰۰	آموزش
amazon_cells_labelled.txt	نظرات محصولات (موبایل)	۱۰۰۰	۵۰۰	۵۰۰	آموزش
yelp_labelled.txt	نظرات رستوران	۱۰۰۰	۵۰۰	۵۰۰	آزمون

به جای تقسیم تصادفی، از یک طرح ارزیابی **بین دامنه‌ای (Cross-Domain)** استفاده شده است: مدل روی ۲۰۰۰ جمله فیلم و محصولات (imdb + amazon) آموزش می‌بیند و روی ۱۰۰۰ جمله رستوران (yelp) — دامنه‌ای که هرگز ندیده است — آزمایش می‌شود. این سنجش از تقسیم تصادفی سخت‌گیرانه‌تر است و توانایی تعمیم واقعی مدل را می‌سنجد. کلاس‌ها کاملاً متوازن‌اند (۵۰۰/۵۰۰)، بنابراین دقت (Accuracy) معیار معناداری است و خط پایه تصادفی ۵۰٪ است.

۳. مراحل پیش‌پردازش

مطابق صورت پروژه، شش مرحله پیش‌پردازش زیر به ترتیب روی هر جمله اجرا می‌شود؛ همه این مراحل در ماژول‌های جداگانه پوشه src/ به صورت دستی پیاده‌سازی شده‌اند:

مرحله	شرح پیاده‌سازی	ماژول
تبدیل حروف به Lowercase	تبدیل تمام حروف به حروف کوچک انگلیسی	text_cleaner.py
حذف علائم نگارشی	حذف URL و ایمیل با عبارت باقاعده، سپس حذف هر نویسه‌ای جز حروف a-z و فاصله	text_cleaner.py
حذف اعداد	با همان الگوی [^a-z\s] تمام ارقام نیز حذف می‌شوند	text_cleaner.py
Tokenization	شکستن جمله به کلمات بر اساس فاصله	tokenizer.py
حذف Stop Words	حذف کلمات پرتکرار و بی‌ار احساسی (the, is, and, a, of, to) و ... با فهرست دستی	stopwords.py
Stemming	ریشه‌یابی پسوندی: حذف پسوندهای ing / ed / ly / es / s از انتهای کلمات به شرط باقی ماندن ریشه کافی	stemmer.py

مثال: جمله "Wow... Loved this place!" پس از پاک‌سازی به "wow loved this place"، پس از توکن‌سازی به [wow, loved, this, place]، پس از حذف ایست‌واژه‌ها به [wow, loved, place] و پس از ریشه‌یابی به [wow, lov, place] تبدیل می‌شود.

۴. استخراج ویژگی با TF-IDF

پس از پیش‌پردازش، ابتدا واژگان (Vocabulary) فقط از روی داده‌های آموزش ساخته می‌شود تا هیچ نشئت داده‌ای (Data Leakage) از مجموعه آزمون رخ ندهد؛ سپس هر جمله با مدل کیسه کلمات (Bag of Words) به بردار شمارش و در ادامه به بردار TF-IDF تبدیل می‌شود. کلمات خارج از واژگان آموزش در زمان آزمون نادیده گرفته می‌شوند.

وزن هر کلمه از حاصل ضرب دو مؤلفه به دست می‌آید: فراوانی نسبی کلمه در سند (TF) و معکوس فراوانی سندی هموارشده (IDF):

$$tf(t, d) = \text{count}(t, d) / |d| \quad idf(t) = \ln((N + 1) / (df(t) + 1)) + 1$$

که در آن N تعداد کل اسناد آموزش و $df(t)$ تعداد اسنادی است که کلمه t در آن‌ها آمده است. هموارسازی $(+1)$ از تقسیم بر صفر و لگاریتم صفر جلوگیری می‌کند. IDF فقط روی داده آموزش fit و روی داده آزمون صرفاً $transform$ می‌شود.

ابعاد ماتریس TF-IDF (مطابق خواسته صورت پروژه): اندازه واژگان استخراج‌شده از ۲۰۰۰ جمله آموزش برابر **۳۴۹۳ کلمه** است؛ بنابراین:

ابعاد (سند × ویژگی)	ماتریس
2000 × 3493	ماتریس TF-IDF آموزش
1000 × 3493	ماتریس TF-IDF آزمون

۵. آموزش مدل

برای طبقه‌بندی از الگوریتم **Multinomial Naive Bayes** استفاده شده که به‌طور کامل دستی پیاده‌سازی شده است (src/naive_bayes.py). مدل بر اساس قاعده بیز، برای هر کلاس c احتمال پسین را متناسب با عبارت زیر محاسبه می‌کند:

$$\log P(c | d) \propto \log P(c) + \sum_{t \in d} w_{t,d} \cdot \log P(t | c)$$

نکات پیاده‌سازی:

- **هموارسازی لاپلاس (افزودن یک):** برای آن‌که کلمه‌ای که در داده آموزش یک کلاس دیده نشده، احتمال آن کلاس را صفر نکند، شمارش همه کلمات با مقدار اولیه ۱ آغاز می‌شود.
- **محاسبات لگاریتمی و نرمال‌سازی log-sum-exp:** برای جلوگیری از زیرریز عددی (Underflow)، همه ضرب‌ها در فضای لگاریتم انجام و در پایان، احتمال‌ها با ترفند log-sum-exp به احتمال‌های نرمال (با مجموع ۱) تبدیل می‌شوند؛ به همین دلیل مدل علاوه بر برچسب، **میزان اطمینان** خود را نیز گزارش می‌کند.
- **قابلیت افزودن کلاس خنثی:** به‌عنوان یک افزونه اختیاری، اگر اختلاف احتمال دو کلاس از آستانه ۰٫۳ کمتر باشد، مدل به‌جای حدس پرریسک، برچسب «خنثی» (عدم قطعیت) برمی‌گرداند. در ارزیابی اصلی گزارش (بخش ۶) این آستانه غیرفعال است تا نتایج دقیقاً مطابق صورت پروژه و به‌صورت دوکلاسه گزارش شود.

۶. نتایج

نتایج زیر حاصل آموزش روی ۲۰۰۰ جمله imdb + amazon و ارزیابی روی ۱۰۰۰ جمله yelp (دامنه دیده نشده) است. همه معیارها (Accuracy, Precision, Recall, F1) نیز به صورت دستی و تنها با شمارش TP/FP/FN پیاده سازی شده اند (src/metrics.py).

دقت کل (Accuracy): ۷۷,۵٪ (در برابر خط پایه ۵۰٪، آن هم روی دامنه ای کاملاً متفاوت از داده آموزش)

تعداد نمونه	F1-score	Recall	Precision	کلاس
۵۰۰	78.1%	80.2%	76.1%	منفی (0)
۵۰۰	76.9%	74.8%	79.1%	مثبت (1)
۱۰۰۰	77.5%	77.5%	77.6%	میانگین (Macro)

ماتریس درهم ریختگی (Confusion Matrix): سطرها برچسب واقعی و ستون ها پیش بینی مدل اند.

	پیش بینی: منفی	پیش بینی: مثبت
واقعی: منفی	401	99
واقعی: مثبت	126	374

مدل در تشخیص جمله های منفی اندکی بهتر عمل می کند (بازیابی ۸۰,۲٪ در برابر ۷۴,۸٪؛ دلیل آن این است که واژه های منفی (bad, worst, poor و ...) بین دامنه ها مشترک ترند، در حالی که بخشی از واژگان مثبت حوزه رستوران (مانند tasty و delicious) در داده آموزش (فیلم و موبایل) کم بسامد یا غایب اند.

نتایج با فعال بودن کلاس خنثی (آستانه ۰,۳ — افزونه پروژه): مدل ۱۹۴ جمله مبهم را «خنثی» اعلام می کند و روی ۸۰۶ جمله ای که با اطمینان پاسخ می دهد، دقت به ۸۱,۴٪ می رسد؛ یعنی آستانه اطمینان، خطاهای پریسک را به درستی فیلتر می کند.

آموزنده ترین کلمات هر کلاس (بر اساس نسبت لگاریتمی احتمال کلمه در یک کلاس به کلاس مقابل؛ کلمات به شکل ریشه یابی شده آمده اند):

کلاس مثبت	کلاس منفی
nice, great, excellent, love, beautiful, brilliant, incredible, awesome, lov, price	poor, horrible, suck, disappoint, worst, awful, bad, disappointment, junk, stupid

۷. تحلیل خطاها

از مجموع ۲۲۵ خطای مدل در حالت دوکلاسه، ۱۰ نمونه شاخص انتخاب و دلیل هر خطا به طور جداگانه بررسی شده است. برای هر نمونه، ادعای مطرح شده با آمار واقعی مدل (احتمال کلمه در هر کلاس و حضور یا غیبت کلمه در واژگان آموزش) راستی آزمایی شده است.

نمونه ۱ — واقعی: مثبت | پیش‌بینی: منفی (اطمینان ۴۵٪)

"I found this place by accident and I could not be happier."

دلیل — نفی معکوس‌کننده: عبارت "could not be happier" یک اصطلاح کاملاً مثبت است، اما مدل کیسه کلمات ترتیب و ترکیب را نمی‌بیند؛ کلمه not در داده آموزش قویاً منفی است (حدود ۵/۷ برابر بیشتر در جمله‌های منفی دیده شده) و همین کلمه پیش‌بینی را منفی می‌کند، در حالی که این‌جا «not + صفت تفضیلی» معنای «حداکثر مثبت» دارد.

نمونه ۲ — واقعی: منفی | پیش‌بینی: مثبت (اطمینان ۴۳٪)

"They never brought a salad we asked for."

دلیل — منفی ضمنی + کلمات خارج از واژگان: این شکایت هیچ صفت منفی صریحی ندارد؛ منفی بودن آن ضمنی است (نیارودن سفارش). کلمات محتوایی آن مانند salad اصلاً در واژگان آموزش وجود ندارند و نادیده گرفته می‌شوند؛ تنها سیگنال ضعیف never برای غلبه بر بقیه کلمات خنثی کافی نیست.

نمونه ۳ — واقعی: منفی | پیش‌بینی: مثبت (اطمینان ۹۷٪)

"It was pretty gross!"

دلیل — چندمعنایی + کلمه ناشناخته: تنها کلمه حامل احساس یعنی gross در داده آموزش (نقد فیلم و موبایل) هرگز دیده نشده و به کلی حذف می‌شود. از طرف دیگر pretty که این‌جا قید شدت است («خیلی»)، در داده آموزش بیشتر به معنای «زیبا» و در جمله‌های مثبت آمده است؛ نتیجه، یک خطای با اطمینان بالاست.

نمونه ۴ — واقعی: مثبت | پیش‌بینی: منفی (اطمینان ۹۹٪)

"The portion was huge!"

دلیل — تغییر دامنه (Domain Shift): در دامنه رستوران، «پرس بزرگ» تعریف است؛ اما در داده آموزش، huge عمدتاً در بافت‌های منفی آمده (مانند huge disappointment) و حدود ۲/۸ برابر بیشتر در جمله‌های منفی دیده شده است. کلمه portion نیز در واژگان آموزش وجود ندارد، پس تنها گواه باقی‌مانده همان huge منفی‌ناماست.

نمونه ۵ — واقعی: مثبت | پیش‌بینی: منفی (اطمینان ۹۴٪)

"Will be back again!"

دلیل — تغییر دامنه: «دوباره برمی‌گردم» در نظرات رستوران یعنی رضایت کامل؛ اما در نظرات خرید محصول، back تقریباً همیشه در بافت «پس فرستادن کالا» (sent it back) آمده و حدود ۴/۷ برابر بیشتر در جمله‌های منفی دیده شده است. معنای مثبت و وابسته به دامنه، برعکس تفسیر می‌شود.

نمونه ۶ — واقعی: منفی | پیش‌بینی: مثبت (اطمینان ۹۶٪)

"The management is rude."

دلیل — کلمه کلیدی خارج از واژگان (OOV): کلمه rude — تنها حامل بار منفی جمله — حتی یک بار هم در ۲۰۰۰ جمله آموزشی نیامده است (بی‌ادبی کارکنان مفهومی مخصوص دامنه خدمات است). با حذف آن، هیچ سیگنال منفی باقی نمی‌ماند و کلمات خنثای باقی‌مانده به سمت مثبت می‌لغزند.

نمونه ۷ — واقعی: مثبت | پیش‌بینی: منفی (اطمینان ۹۰٪)

"I was seated immediately."

دلیل — احساس ضمنی بدون واژه احساسی: مثبت بودن این جمله (نشستن فوری = سرویس سریع) کاملاً ضمنی است و هیچ صفت مثبتی ندارد. در داده آموزش، ریشه immediate بیشتر در شکایت‌ها دیده شده (مثلاً «بلافاصله خراب شد») و حدود ۲/۳ برابر به کلاس منفی متمایل است.

نمونه ۸ — واقعی: مثبت | پیش‌بینی: منفی (اطمینان ۸۰٪)

"Omelets are to die for!"

دلیل — اصطلاح (Idiom): عبارت "to die for" یعنی «فوق‌العاده»، اما مدل فقط کلمات منفرد را می‌بیند: die به‌تنهایی واژه‌ای با بار منفی است و omelet نیز در واژگان آموزش نیست. معنای مجازی اصطلاح در سطح تک‌کلمه قابل بازیابی نیست.

نمونه ۹ — واقعی: مثبت | پیش‌بینی: منفی (اطمینان ۹۶٪)

"The only redeeming quality of the restaurant was that it was very inexpensive."

دلیل — احساس مرکب / تعریف نیش‌دار: این جمله حتی برای انسان هم مرزی است: ساختار «تنها نکته مثبتش این بود که...» در واقع نوعی انتقاد همراه با یک امتیاز مثبت است. کلمه only در داده آموزش حدود ۳ برابر بیشتر در جمله‌های منفی آمده و بار منفی ساختار جمله را تقویت می‌کند؛ برچسب مثبت دیتاست فقط به بخش «ارزان بودن» توجه کرده است.

نمونه ۱۰ — واقعی: منفی | پیش‌بینی: مثبت (اطمینان ۷۳٪)

"The pancakes everyone are raving about taste like a sugary disaster tailored to the palate of a six year old."

دلیل — طعنه (Sarcasm): منفی بودن این جمله از تقابل «همه ازش تعریف می‌کنند» با «فاجعه شیرین بچگانه» فهمیده می‌شود، نه از تک‌کلمه‌ها. کلمات ظاهراً خنثی یا مثبت (everyone, taste, like) اکثریت دارند و تنها واژه منفی یعنی disaster در داده آموزش کم‌بسامد است و وزن کافی برای جبران ندارد. تشخیص طعنه ذاتاً فراتر از توان مدل کیسه کلمات است.

جمع‌بندی الگوهای خطا: خطاهای مدل در پنج الگوی اصلی می‌گنجد: (۱) ناتوانی کیسه کلمات در فهم نفی و اصطلاحات، (۲) کلمات خارج از واژگان به‌دلیل آموزش روی دامنه متفاوت، (۳) تغییر معنای کلمات بین دامنه‌ها (مانند back و huge)، (۴) احساس ضمنی بدون واژه احساسی صریح و (۵) طعنه و احساس مرکب. این تحلیل نشان می‌دهد بخش بزرگی از خطاها ناشی از ماهیت ارزیابی بین‌دامنه‌ای و محدودیت ذاتی بازنمایی تک‌کلمه‌ای است، نه اشکال در پیاده‌سازی.

۸. نتیجه‌گیری

در این پروژه یک سامانه کامل تحلیل احساسات — شامل شش مرحله پیش‌پردازش، استخراج ویژگی TF-IDF و طبقه‌بند بیز ساده چندجمله‌ای — به‌طور کامل از پایه و بدون هیچ کتابخانه آماده پیاده‌سازی شد. مدل روی دامنه‌ای کاملاً دیده‌نشده به دقت **۷۷٫۵٪** (و با فیلتر اطمینان، **۸۱٫۴٪** روی پاسخ‌های قطعی) رسید که برای مدلی به این سادگی و در شرایط ارزیابی بین‌دامنه‌ای، نتیجه‌ای قابل قبول است و فاصله معناداری با خط پایه ۵۰٪ دارد.

تحلیل خطاها نشان داد محدودیت‌های اصلی، ذاتی بازنمایی کیسه کلمات است: نفی، اصطلاح، طعنه و جابه‌جایی معنایی بین دامنه‌ها. بر همین اساس، مسیرهای بهبود پیشنهادی عبارت‌اند از: افزودن n-gram ها (به‌ویژه دوتایی‌ها برای گرفتن نفی مانند not good)، مدیریت صریح نفی در پیش‌پردازش، استفاده از ریشه‌یاب کامل‌تر (مانند الگوریتم Porter)، گسترش فهرست ایست‌واژه‌ها، افزودن بخشی از داده هم‌دامنه به آموزش و در نهایت مقایسه با بازنمایی‌های معنایی مدرن (Word Embedding و مدل‌های زبانی) به‌عنوان کار آینده.